

Hlboké neurónové siete 2026

Projekt č. 1

Cieľ úlohy:

Porovnajte tréovanie vybraných modelov konvolučných neurónových sietí, vizuálnych transformerov a hybridných modelov. Na tréovanie modelov použite transferové učenie - transfer learning (TL) a pridelený dataset. Cieľom je overiť, ako sa pri rovnakom probléme mení úspešnosť klasifikácie, stabilita výsledkov a priebeh učenia pri rôznych architektúrach modelov a nastavení parametrov tréovania.

Porovnávajúte nasledovné modely:

1. M1 – CNN: ResNet alebo MobileNet alebo EfficientNet (vybrať vhodný model a verziu)
2. M2 – CNN + attention vrstva: Model M1 + CBAM
3. M3 – Optimalizovaná CNN: ConvNeXt
4. M4 – Vizuálny transformer: ViT, DeiT, Swin
5. M5 – Hybridný model: CoAtNet

Pridelený Dataset náhodne rozdeľte v pomere 80% dát na tréovanie a 10% dát na validáciu a 10% dát na testovanie (Např. z datasetu z každej skupiny vyberiem 1000 vzoriek – 800 tréovanie, 100 validácia, 100 testovanie). V prípade malého počtu dát si pohľadajte iný zdroj obrazov a rozšírite dataset, alebo validačné data použite aj na testovanie. Pred tréovaním modelov nastavte vhodné parametre tréovania. Pri prezentácii projektu zdôvodnite výber štruktúry a parametrov tréovania. Snažte sa používať rovnaké parametre tréovania pri všetkých modeloch. Pre každý model spustite tréovanie 3-krát a výsledky štatisticky vyhodnoťte.

Pre najlepší natréovaný model z každého typu zobrazte proces tréovania (priebeh Loss a Acc na tréovacích a validačných dátach). Na testovacích obrazových dátach nepoužitých v tréovaní vykonajte testovanie jednotlivých modelov a vyčísľte úspešnosť ACC, presnosť Precision a senzitivitu Recall. Pre testovacie data robajte aj kontingenčnú tabuľku. Pre vybrané testovacie vzorky (dobré aj zle klasifikované) vykonajte vizualizáciu rozhodovania CNN. (např. GradCAM metóda)

Aspoň pre jeden model ukážte vplyv augmentácie na úspešnosť klasifikácie. Porovnajte pri vybranej štruktúre siete tréovanie bez augmentácie a s augmentáciou.

Aspoň pre jeden model realizujte postupné rozmrazovanie vrstiev (alebo tréovanie od nuly) predtrénovanej siete a odsledujte vplyv na úspešnosť klasifikácie.

Datasety:

Na tréovanie CNN sietí použite nasledovné vybrané obrazy z datasetov (GitHub <https://github.com/STU-FEI-OUI/HNS-Projekt1/edit/main/README.md>, Goggle disk, HNS_2025/Cvicenia/Projekt1/Datasety_Projekt1 alebo Kaggle datasety:

1. Dataset Vozidlá - Vehicles Dataset

Klasifikácia obrazov, 6 skupín (auto, autobus, bicykel, motorka, dodávka, pickup)
https://drive.google.com/drive/folders/1ETYPjMKG3aPFdnf-RIiWp82HwKq1R4nX?usp=drive_link

Doplniť obrazy vozidiel je možné cez datasety MS COCO, ImageNet dataset, alebo Kaggle
<https://www.kaggle.com/datasets/iamsandeepprasad/vehicle-data-set>

2. Dataset Dopravné Značky - Traffic Signs Dataset

Klasifikácia obrazov, 12 skupín (vybrané typy značiek)

https://drive.google.com/drive/folders/1JShYe8vmZv287GCPLxERNt2PP3C3hwZv?usp=drive_link

3. Dataset Vnútorné prostredie - InDoor Dataset

Klasifikácia obrazov, 9 skupín (vnútorné priestory reštaurácia, obývačka, spálňa, kuchyňa, ...)

https://drive.google.com/drive/folders/1nWlwbR2opcynCSwm_WN97URv_WC-3MVy?usp=drive_link

4. Dataset Ochorenia Paradajok - Plant Village 2

Klasifikácia obrazov, 9 skupín ochorenia listov paradajok (zdravé, 8 skupín ochorenia)

https://drive.google.com/drive/folders/1sKmmi0L4KeSf5xgxXhldCrks4oF897DX?usp=drive_link

Tiež je k dispozícii na Kaggle , <https://www.kaggle.com/datasets/emmarex/plantdisease>

5. Dataset Počasie - Weather Dataset

Klasifikácia obrazov, 11 skupín počasia (dew, fogsmog, frost, glaze, hail, lightning, rain, rainbow, rime, sandstorm, snow)

<https://www.kaggle.com/code/adrianograms/weather-image-classification/input>

Doplniť obrazy počasia je možné cez datasety na Kaggle

https://drive.google.com/drive/folders/1XMSb5IRHJP8PhjMwVJNal7SmHFOduRij?usp=drive_link

<https://www.kaggle.com/code/ramazanturann/weather-image-classification/input>

6. Dataset Architektúry - Architecture Dataset

Klasifikácia obrazov, 25 skupín typov architektúr budov

https://drive.google.com/drive/folders/13hPJY3ZBmGQp1_AwKQUTMrs3ei2GhFvs?usp=drive_link

7. Dataset Kvety - Flowers Dataset

Klasifikácia obrazov, 5 druhov kvetov (daisy, dandelion, rose, sunflower, tulip)

<https://www.kaggle.com/code/nikhilmishra21/flowers-notebook-cnn/input>

8. Dataset Kvety - Flowers Dataset – Oxford 102 flowers

Klasifikácia obrazov, 102 druhov kvetov (použiť minimálne 10 tried, ktoré sú najviac zastúpené)

<https://www.robots.ox.ac.uk/~vgg/data/flowers/102/>

9. Dataset Jedlá - Foods Dataset

Klasifikácia obrazov jedál, 101 skupín obrazov jedál, (použiť minimálne 10 tried, ktoré sú najviac zastúpené), <https://www.kaggle.com/datasets/kmader/food41>

10. Dataset Odpadky 1 - Garbage 1 Dataset

Klasifikácia obrazov odpadkov, 10 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/sumn2u/garbage-classification-v2>

11. Dataset Odpadky 2 - Garbage 2 Dataset

Klasifikácia obrazov odpadkov, 6 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/asdasdasdasdas/garbage-classification/data>

12. Dataset Odpadky 3 - Garbage 3 Dataset

Klasifikácia obrazov odpadkov, 12 skupín obrazov odpadkov
<https://www.kaggle.com/datasets/mostafaabla/garbage-classification>

13. Dataset na detekciu požiaru lesov - Forest Fire Smoke Dataset

Rozpoznávanie požiaru lesov, 3 skupiny Smoke, Fire, Not_Fire
<https://www.kaggle.com/datasets/amerzishminha/forest-fire-smoke-and-non-fire-image-dataset>

14. Dataset PC komponentov – PC components Dataset

Rozpoznávanie PC komponentov, 14 skupín (CPU, GPU, káble, RAM, HDD, monitor, klávesnica, ...)
<https://www.kaggle.com/datasets/asaniczka/pc-parts-images-dataset-classification>

15. Dataset povrchových defektov ocelového pásu – NEU Surface defect Dataset

Klasifikácia defektov ocelového plechu, 6 skupín (valcované okuje (RS), škvrny (Pa), praskliny (Cr), jamkovitý povrch (PS), inklúzie (In) a škrabance (Sc))
<https://www.kaggle.com/datasets/kaustubhdikshit/neu-surface-defect-database/data>

Výsledky projektu zaznamenajte do dokumentácii a spolu s programami vložte do AISu do 7. týždňa. Prezentácie projektov budú v 6. týždni.