Hlboké neurónové siete 2026

Projekt č. 2

V projekte 2 budete vytvárať CNN, ViT a hybridné modely pre úlohy rozpoznávania na datasetoch tvárí, gest, hlasových povelov, medicínskych dát, atď. Na úlohu navrhnite viacero typov modelov, čo najlepšou úspešnosťou. Pre vyhodnotenie úspešnosti klasifikácie realizujte 5 trénovaní. Pre klasifikáciu do dvoch tried vypočítajte aj senzitivitu a špecificitu. Na trénovanie modelov použite nasledovné vybrané datasety. Je možné použiť aj iné datasety z oblasti robotiky a medicíny po dohode s vyučujúcim. Dataset náhodne rozdeľte v pomere 70% dát na trénovanie, 15% dát na validáciu a 15% dát na testovanie. (ak nie sú data rozdelené). Neurónové modely otestujte na testovacích dátach. Pre jednotlivé modely zobrazte kontingenčné tabuľky. Modely porovnajte na základe metrík: úspešnosť (accuracy), presnosť (precision), senzitivita (recall). Ak je možné kvalitu najlepšieho modelu reálne otestujte na kamere (mikrofóne) a dotrénujte model pre zlepšenie výsledkov na kamere. Pre vybrané testovacie vzorky vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)

HMI aplikácie

Repozitár – oblasť HMI aplikácií: https://github.com/STU-FEI-OUI/KEGA-Pracovisko2

Skupina 1: Kontrola nasadeného rúška

- Rozpoznávanie dobre nasadeného rúška – 2 skupiny (dobre nasadené, zle nasadené) alebo 3 skupiny (bez rúška, zle nasadené, dobre nasadené) https://github.com/cabani/MaskedFace-Net. Porovnať rôzne modely (aspoň 3), najlepší model aplikovať na kameru a urobiť testovanie natrénovaného modelu na správne nasadené rúško.

Skupina 2: Hlasové povely

- Rozpoznávanie hlasových povelov zo zvukových nahrávok – 8 skupín povelov (go, left, right, stop, up, down, on, off). Porovnať rôzne modely (Raw-CNN, Raw-CNN-LSTM. Spect-CNN). Aplikovať najlepší model na mikrofón a urobiť testovanie CNN na naučené povely. Zohľadniť aj šum pozadia (prostredia). (Dataset: https://www.kaggle.com/datasets/mok0na/speech-commands-v002)

Skupina 3: Stavy tváre

- Rozpoznávanie natočenia tváre z RGB obrazu – 4 skupiny (LeftProfile, LightOn, RightProfile, OcclusionPaper). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na natočenie tváre.

- Rozpoznávanie gest tváre z RGB obrazu – 5 skupín (Neutral, OcclusionEyes, OcclusionMouth, OpenMouth, Smile). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na gestá tváre.
- (https://drive.google.com/drive/folders/1YwOCplpXusQXr7d9wsS7kTb9TGJAt5fW?usp=drive_link)

Skupina 4: Gestá ASL 1

- Rozpoznávanie gest ruky z RGB obrazu – 10 skupín (jednotlivé gestá). Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na jednotlivé gestá.
- Rozpoznávanie gest ruky z hĺbkovej mapy – 10 skupín (jednotlivé gestá) (Aplikovať aspoň 3 CNN alebo ViT modely)
- (https://drive.google.com/drive/folders/1mpRo653YGYd4iuB-1t5sxog7rBnpaNob?usp=drive_link)

Skupina 5: Gestá ASL 2

- Aplikovať aspoň 3 CNN alebo ViT modely, vybrať najlepší a aplikovať na kameru a urobiť testovanie CNN na jednotlivé gestá.
- Rozpoznávanie gest ruky z hĺbkovej mapy – 10 skupín (jednotlivé gestá) (Aplikovať aspoň 3 CNN alebo ViT modely)
- (https://drive.google.com/drive/folders/1UDefZEX1hMszVGkDu04sFOX3yu9altu9?usp=drive_link)

Aplikácie klasifikácie defektov:

Repozitár – oblasť detekcie defektov: https://github.com/STU-FEI-OUI/KEGA-Pracovisko1

Skupina 6: Defekty 1

- Rozpoznávanie defektov (jám) na ceste - 2 skupiny (Ok, defect) (CNN a ViT, porovnať 3 modely) (https://drive.google.com/drive/folders/1d3atNCQK9POrsjQJiVZ6M8HoPEfCaTn6?usp=drive_link)

- Kontrola kvality podložiek – 5 skupín (Ok, 4 typy defektov) (CNN – porovnať 3 modely) (https://drive.google.com/drive/folders/1PVE357M-8uburXtl5kFwjo_nowSup1Xx?usp=drive_link)

Skupina 7: Defekty 2

- Kontrola kvality zvarov kamery – 4 skupiny (Ok, 2025-kráterový lunker, 510-diera, 500-poškodený povrch zvaru) (CNN a ViT, porovnať 3 modely) (https://drive.google.com/drive/folders/1SUivIX-uDGs74XNegNQp95wvQ78C5DIe?usp=drive_link)

- Kontrola kvality obrobkov - 2 skupiny (Ok, defect) (Autoenkóder a FCDD) (originál data - https://www.kaggle.com/datasets/ravirajsinh45/real-life-industrial-dataset-of-casting-product/data)

Skupina 8: Defekty 3

- Klasifikácia defektov dataset NEU-DET (6 typov defektov) (CNN a ViT, porovnať 3 modely) (https://www.kaggle.com/datasets/rdsunday/neu-urface-defect-database)
- Kontrola kvality pneumatík - 2 skupiny (Ok, defect) (CNN a ViT, porovnať 3 modely) (https://drive.google.com/drive/folders/1EO9dj8x2OM21ZSBs8xlqTLSzH-FDLOBB?usp=drive_link)

Skupina 9: Detekcia ľudských činností

- Rozpoznávanie ľudských činností z videa (aspoň dve činnosti), ktoré je možné pred kamerou názorne otestovať (napr. pitie a jedenie) (napr. dataset HMDB51 alebo UCF101). Použite aspoň dve metódy (CNN+SVM, CNN+LSTM, ...). Najlepšiu metódu aplikujte na kameru.

Repozitár – oblasť detekcie ľuds.činností: https://github.com/STU-FEI-OUI/KEGA-Pracovisko4

Skupina 10: Detekcia anomálii – EKG signály

- Na datasete ECG navrhnite viaceré modely pre rozpoznávanie anomálií pri elektrickej aktivite srdca. Použite nasledovné dvojtriedne modely (SVM, MLP, 1D-CNN, LSTM) a nasledovné jednotriedne modely (autoenkóder, One-Class SVM, Isolation Forest) (dataset ECG - https://www.kaggle.com/datasets/devavratatripathy/ecg-dataset/data).

Repozitár – oblasť detekcie anomálií: https://github.com/STU-FEI-OUI/KEGA-Pracovisko5

Medicínske aplikácie:

Skupina 11:

- Rozpoznávanie Diabetickej Retinopatie (DR) na fundus snímkach očného pozadia. – 5 skupín (No DR – bez DR, Mild – mierna NDR, Moderate – stredne závažná NDR, Severe - závažná NDR, Proliferative DR – Proliferatívna retinopatia). Porovnajte aspoň 3 modely. Najlepší model aplikujte aj na klasifikáciu do 2 skupín (Normal, Positive) . Dataset: (https://www.kaggle.com/datasets/sampathsaivamsimatha/diabetic-rethinopathy-dataset-new)

Skupina 12:

- Rozpoznávanie nálezov na hrubom čreve. (8 skupín nálezov) Dataset KVASIR (https://www.kaggle.com/datasets/meetnagadia/kvasir-dataset).
- (https://drive.google.com/drive/folders/1XJiAKuaDOcOyz5baznfUCP-VB2re3J8s?usp=drive_link)
- Rozpoznávanie ochorenie Aizheimer na MRI obrazoch – 2 skupiny (normal, positive) (https://drive.google.com/drive/folders/1ARzPYGbM_oUccYpTV9js5bKHGwuCYBTg?usp=drive_link)

Postupy a úlohy:

Skupina 1: Kontrola nasadeného rúška

- Použite dataset https://github.com/cabani/MaskedFace-Net
- Zvoľte si 3 skupiny (bez rúška, zle nasadené, dobre nasadené). Analyzujte dataset. Vykonajte vhodné predspracovania obrazu.
- Na rozpoznávanie dobre nasadenia rúška použite aspoň 3 modely rôzneho typu.
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Najlepší model otestujte na kamere. (Vytvorením testovacieho datasetu, 10 nahrávok z každého povelu)
- Pre vybrané testovacie vzorky (dobré aj zlé klasifikácie) vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)
- V prípade veľkého zníženia úspešnosti modelu na kamere, zopakujte trénovanie modelu na doplnenom datasete.

Skupina 2: Hlasové povely

- Použite dataset https://www.kaggle.com/datasets/mok0na/speech-commands-v002
- Zvoľte si 8 skupín hlasových povelov (go, left, right, stop, up, down, on, off) + šum pozadia (prostredia). Analyzujte dataset.
- Na rozpoznávanie hlasových povelov použite RAW signál a Spektrogram (alebo iné grafické znázornenie frekvenčného obsahu signálu)
- Použite modely 1D-CNN a 1D-CNN+LSTM pre vstup RAW signálu, CNN pre vstup Spektrogram alebo iný model. Použite minimálne 3 typy modelov.
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Najlepší model otestujte na mikrofóne. (Vytvorením testovacieho datasetu, 10 nahrávok z každého povelu)
- V prípade veľkého zníženia úspešnosti modelu na mikrofóne, zopakujte trénovanie modelu na doplnenom datasete.

Skupiny 3, 4, 5, 6, 8, 11, 12:

- Použite príslušný dataset. Analyzujte dataset. Vykonajte vhodné predspracovania obrazu.
- Na klasifikačnú úlohu použite aspoň 3 modely rôzneho typu.
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Pre vybrané testovacie vzorky (dobré aj zlé klasifikácie) vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)
- Pri skupinách 3, 4 a 5 najlepší model otestujte na kamere. (Vytvorením testovacieho datasetu, 10 nahrávok z každej skupiny)
- V prípade veľkého zníženia úspešnosti modelu na kamere, zopakujte trénovanie modelu na doplnenom datasete.

Skupina 7: Defekty 2

- Použite príslušné datasety. Analyzujte datasety. Vykonajte vhodné predspracovania obrazu.
- Na 1. klasifikačnú úlohu použite aspoň 3 modely rôzneho typu, na 2. klasifikačnú úlohu použite neurónové modely typu autoenkóder a FCDD.
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Pre vybrané testovacie vzorky (dobré aj zlé klasifikácie) vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)

Skupina 9: Detekcia ľudských činností

- Použite príslušné datasety. Analyzujte datasety. Vyberte si aspoň 2 činnosti na rozpoznávanie.
- Použite aspoň 2 modely rôzneho typu (napr. CNN, CNN+SVM, CNN+LSTM, ...)
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Pre vybrané testovacie vzorky (dobré aj zlé klasifikácie) vykonajte vizualizáciu rozhodovania modelov. (napr. GradCAM metóda)
- Najlepší model otestujte na kamere. (Vytvorením testovacieho datasetu, 10 nahrávok z každej skupiny)
- V prípade veľkého zníženia úspešnosti modelu na kamere, zopakujte trénovanie modelu na doplnenom datasete.

Skupina 10: Detekcia anomálii – EKG signály

- Použite dataset ECG5000 - https://www.kaggle.com/datasets/devavratatripathy/ecg-dataset/data. Analyzujte dataset.

- Na datasete ECG5000 navrhnite viaceré modely pre rozpoznávanie anomálií pri elektrickej aktivite srdca. Použite nasledovné dvojtriedne modely (SVM, MLP, 1D-CNN, LSTM) a nasledovné jednotriedne modely (autoenkóder, One-Class SVM, Isolation Forest).
- Vykonajte trénovanie každého modelu 5 krát. Modely porovnajte na základe metrík klasifikácie.
- Porovnajte najlepší dvojtriedny a najlepší jednotriedny model.

Výsledky projektu zaznamenajte do dokumentácii a spolu s programami vložte do AISu do 12. týždňa.