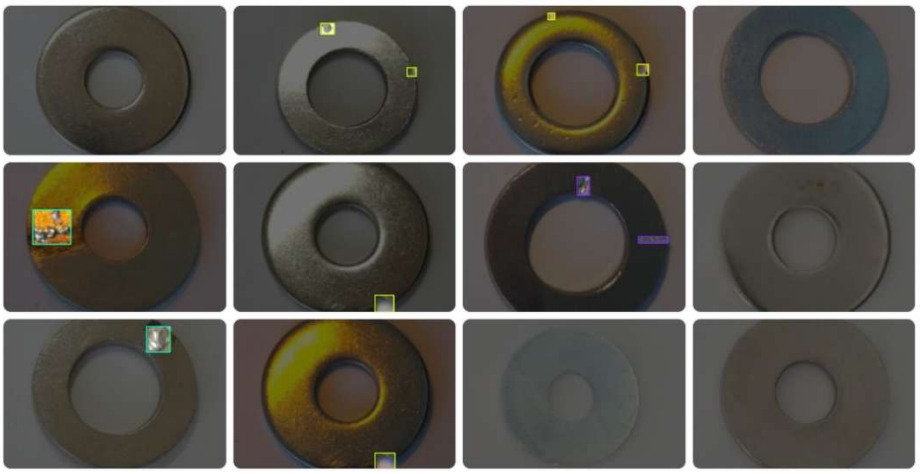
Hlboké neurónové siete 2026

Zadanie č. 2

Na základe demo ukážok v prednáške, vytvorte a natrénujte YOLO detektor na datasete podložiek, kde detektor má za úlohu detegovať 4 typy defektov (jamka - circular_cavity, šrabanec - scratch, zárez – burr, prevýšenie materiálu - excess_material). Pre YOLO detektor si môžete vybrať ľubovoľnú verziu. Na porovnanie natrénujte ešte jeden typ detektora. Môžete si vybrať z nasledovných typov DETR, RT-DETR, DINO, faster-RCNN. Pre YOLO detektor si vykonajte trénovanie bez augmentácie a s augmentáciou. Pre úpravu obrazov a označovanie objektov využite napr. nástroj Roboflow (https://roboflow.com/).

Dataset s defektami podložiek sa nachádza na
https://universe.roboflow.com/hemorrhagesegmentation/tp26_detection

Alebo na Google Disku – súbor Dataset_Podlozky_Detekcia.zip
https://drive.google.com/drive/folders/1QcswFcZ1FPBEZM2TyV8x0bvTimcJgAfQ?usp=drive_link



Obr. 1 Ukážky nasnímaných podložiek s označením defektov

Dataset je už rozdelený na trénovaciu, validačné a testovaciu časť. Pre trénovanie detektorov nájdite vhodné hyperparametre. (veľkosť modelu, optimalizátor učenia, krok učenia, veľkosť dávky, ...). Zobrazte priebehy učenia detektorov. Na testovacích dátach zobrazte priebeh krivky pre priemernú presnosť (Average Precision) (precision-recall krivku). Tiež vyčíslite hodnoty metrík Precision, Recall, mAP50 pre validačné a testovacie dáta. Zistite vplyv augmentácie na úspešnosť detektora. Pri dodržaní rovnakých spoločných hyperparametrov natrénujte iný typ detektora na porovnanie s YOLO detektorom. Nafoťte, vyrežte, resizujte na rozmer 512x512 a označte defekty, na 5 obrazov z každého defektu podložky, ktoré samostatne otestujte detektormi. Označené obrazy uložte na Google disk ku datasetu, do adresára Testovacie_obrazy_podloziek. Porovnajte úspešnosť jednotlivých detektorov.

Prílohy:

Linky pre realizáciu detektorov:

PyTorch

YOLOv11
https://docs.ultralytics.com/models/yolo11/#usage-examples
Trénovanie (Príklady a tutorial): https://docs.ultralytics.com/usage/python/#train
GitHub - ultralytics/ultralytics: Ultralytics YOLO 🚀 (https://github.com/ultralytics/ultralytics)

YOLOv8 a **YOLO** všeobecne:

https://github.com/ultralytics/ultralytics

https://pytorch.org/vision/stable/models.html#object-detection

https://blog.roboflow.com/how-to-train-yolov8-on-a-custom-dataset/

YOLOv5

https://github.com/ultralytics/yolov5

https://github.com/ultralytics/yolov5/blob/master/tutorial.ipynb

https://www.digitalocean.com/community/tutorials/train-yolov5-custom-data

---

Faster-RCNN

https://pytorch.org/tutorials/intermediate/torchvision_tutorial.html

https://github.com/harshatejas/pytorch_custom_object_detection\

https://www.kaggle.com/code/drindeng/cell-images-object-detection-model-with-pytorch/notebook

---

Ďalšie linky:

Faster R-CNN GitHub - pytorch/vision: Datasets, Transforms and Models specific to Computer Vision

Yolo10-26 GitHub - ultralytics/ultralytics: Ultralytics YOLO27, YOLO26, YOLO11, YOLOv8 — object detection, ins…

RF-DETR N/S https://github.com/roboflow/rf-detr

RT-DETRv2-S https://github.com/lyuwenyu/RT-DETR

D-FINE-S https://github.com/Peterande/D-FINE

DINO Swin-T https://github.com/IDEA-Research/detrex

ViTDet-B https://github.com/facebookresearch/detectron2

R-CNN Swin-T https://github.com/open-mmlab/mmdetection

Attention U-Net https://github.com/Project-MONAI/MONAI

TransUNet https://github.com/Beckschen/TransUNet

Datasets, Transforms and Models specific to Computer Vision - pytorch/vision

---

Augmentacia:

https://albumentations.ai/docs/getting_started/bounding_boxes_augmentation/